

Relatório de Experimentação — Árvore de Decisão

Previsão de Risco de Evasão em Cursos de Educação Superior

Manus AI

Junho de 2026

Resumo

Este relatório apresenta os resultados da experimentação com o modelo de Árvore de Decisão (Decision Tree) otimizado para a predição de alto risco de evasão universitária. O experimento utilizou microdados do Censo da Educação Superior 2024 e implementou melhorias de alto impacto, incluindo engenharia de features avançada, seleção de atributos via Informação Mútua (Mutual Information), balanceamento de classes com SMOTE e otimização de hiperparâmetros via RandomizedSearchCV. Para garantir a generalização e evitar o sobreajuste (overfitting), aplicou-se a técnica de pós-poda (Cost Complexity Pruning) e ajuste dinâmico do limiar de decisão. O modelo final demonstrou um desempenho robusto, alcançando um F1-Score médio de 0.859 e revelando a importância crítica de variáveis como a razão entre ingressantes e matriculados e taxas de conclusão.

Sumário

- Contextualização do Problema
- Fundamentos Teóricos da Árvore de Decisão
 - 2.1. Estrutura e Divisões (Splits)
 - 2.2. Critérios de Impureza (Gini e Entropia)
 - 2.3. Poda (Pruning) e Complexidade
- Pré-processamento e Engenharia de Features
 - 3.1. Features Avançadas e Interações
 - 3.2. Seleção de Atributos (Mutual Information)
 - 3.3. Balanceamento de Classes (SMOTE)
- Metodologia Experimental
 - 4.1. Otimização de Hiperparâmetros
 - 4.2. Pós-Poda (Cost Complexity Pruning)
 - 4.3. Validação Cruzada e Threshold Tuning
- Resultados e Discussão
 - 5.1. Desempenho Consolidado (5-Fold)
 - 5.2. Importância das Features
 - 5.3. Análise da Estrutura da Árvore
- Conclusões Finais

1. Contextualização do Problema

O estudo foca na **classificação binária de cursos de graduação** com base no risco de evasão. A variável `ALTO_RISCO_EVASAO` (1 para taxa $\geq 20\%$, 0 caso contrário) apresenta um desbalanceamento natural (75,4% vs 24,6%). Diferente dos modelos lineares, a Árvore de Decisão foi escolhida por sua capacidade de capturar relações não lineares e interações complexas entre as variáveis socioeconômicas e acadêmicas dos cursos.

2. Fundamentos Teóricos da Árvore de Decisão

2.1. Estrutura e Divisões (Splits)

A Árvore de Decisão é um modelo não paramétrico que particiona o espaço de características em regiões retangulares. A cada nó, o algoritmo escolhe a feature e o valor de corte que melhor separa as classes, visando maximizar a pureza dos nós filhos [1].

2.2. Critérios de Impureza (Gini e Entropia)

O experimento utilizou predominantemente o **Índice Gini**, que mede a probabilidade de um elemento ser classificado incorretamente se for rotulado aleatoriamente de acordo com a distribuição daquele nó. Alternativamente, a **Entropia** (Ganho de Informação) também foi explorada na busca de hiperparâmetros para avaliar a redução da incerteza após cada divisão [2].

2.3. Poda (Pruning) e Complexidade

Árvores de decisão são propensas ao *overfitting*, crescendo até memorizar o ruído do treino. A técnica de **Cost Complexity Pruning** (α) foi implementada para encontrar a árvore que minimiza uma função de custo que penaliza o número de nós terminais, garantindo um modelo mais simples e generalizável [3].

3. Pré-processamento e Engenharia de Features

3.1. Features Avançadas e Interações

Foram criadas 10 novas features para enriquecer o modelo, destacando-se:

- **RAZAO_CONCLUSAO_EVASAO**: Medida de eficiência acadêmica.
- **CURSO_COMPETITIVO**: Razão inscritos/vagas superior a 2.
- **RAZAO_FINANC_EAD**: Interação entre financiamento e modalidade.

- **TAMANHO_CATEGORIA**: Discretização do número de ingressantes.

3.2. Seleção de Atributos (Mutual Information)

Utilizou-se o `SelectKBest` com **Mutual Information** para selecionar as 23 features mais informativas. Diferente da correlação linear, a informação mútua captura qualquer tipo de dependência estatística entre a feature e o alvo, sendo ideal para modelos de árvore [4].

3.3. Balanceamento de Classes (SMOTE)

Para compensar o desbalanceamento, aplicou-se o **SMOTE** (Synthetic Minority Over-sampling Technique) no conjunto de treino. Esta técnica cria exemplos sintéticos da classe minoritária (Baixo Risco) baseando-se nos vizinhos mais próximos, permitindo que a árvore aprenda melhor as fronteiras de decisão dessa classe [5].

4. Metodologia Experimental

4.1. Otimização de Hiperparâmetros

O `RandomizedSearchCV` realizou 200 iterações explorando:

- `max_depth` : de 5 a 50.
- `min_samples_split` e `min_samples_leaf` : para controlar o crescimento.
- `ccp_alpha` : para a pós-poda.

4.2. Validação Cruzada e Threshold Tuning

O modelo foi validado com **5-Fold Cross-Validation**. Em cada fold, o limiar de decisão foi ajustado dinamicamente para maximizar o F1-Score, garantindo que o modelo não fosse excessivamente conservador ou liberal nas predições de risco.

5. Resultados e Discussão

5.1. Desempenho Consolidado (5-Fold)

O modelo apresentou uma estabilidade notável, com métricas equilibradas entre precisão e sensibilidade.

Tabela 1: Síntese Estatística (Média ± Desvio Padrão)

Métrica	Valor Médio	Desvio Padrão
Acurácia	0.7538	± 0.0006
F1-Score	0.8596	± 0.0004
Precisão	0.7542	± 0.0002
Recall	0.9991	± 0.0013

5.2. Importância das Features

A análise de importância revelou que o modelo baseia suas decisões em fatores estruturais e de fluxo acadêmico.

Tabela 2: Top 5 Features Mais Importantes

Feature	Importância Média
RAZAO_ING_MAT	0.3590
QT_ING	0.2355
RAZAO_CONCLUSAO_EVASAO	0.1979
TAXA_CONCLUSAO	0.1023
QT_MAT	0.0810

A feature `RAZAO_ING_MAT` (razão entre ingressantes e matriculados) foi o principal preditor, sugerindo que a dinâmica de renovação do corpo discente é o sinal mais forte de risco de evasão.

5.3. Análise da Estrutura da Árvore

A árvore final apresentou uma **profundidade média de 34.6 níveis**. Embora profunda, a aplicação do `ccp_alpha` (poda) garantiu que os ramos mais profundos tivessem ganho estatístico real, evitando a memorização de casos isolados.

6. Conclusões Finais

A Árvore de Decisão otimizada provou ser uma ferramenta poderosa para entender a evasão universitária. Suas principais vantagens observadas foram:

1. **Poder Explicativo:** Através das importâncias das features, identificamos que o fluxo de alunos (ingressantes/matriculados) é mais determinante que o perfil demográfico puro.
2. **Eficácia do SMOTE:** O balanceamento sintético permitiu que o modelo mantivesse um recall altíssimo (99.9%) sem degradar a precisão.
3. **Robustez via Poda:** A técnica de Cost Complexity Pruning permitiu o uso de uma árvore profunda de forma segura, capturando nuances que modelos lineares ignorariam.

Em conclusão, a Árvore de Decisão oferece um equilíbrio ideal entre performance preditiva e *insights* sobre os fatores de risco, sendo recomendada para cenários onde a explicação do “porquê” de um curso estar em risco é tão importante quanto a predição em si.

Referências

- [1] Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (1984). *Classification and Regression Trees*. CRC Press.
- [2] Quinlan, J. R. (1986). *Induction of Decision Trees*. Machine Learning, 1(1), 81-106.
- [3] Scikit-learn. *Decision Tree Pruning Guide*. Disponível em: https://scikit-learn.org/stable/auto_examples/tree/plot_cost_complexity_pruning.html
- [4] Kraskov, A., Stögbauer, H., & Grassberger, P. (2004). *Estimating Mutual Information*. Physical Review E.
- [5] Chawla, N. V., et al. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research.