

Relatório — Naive Bayes (Evasão Acadêmica)

1. Objetivo

Este trabalho aborda a classificação de cursos de educação superior quanto ao risco de evasão acadêmica, utilizando microdados do Censo da Educação Superior (INEP). O objetivo é identificar cursos com elevada taxa de desvinculação de alunos, priorizando a métrica **Recall** para maximizar a detecção de casos de alto risco.

2. Estratégia de Pré-processamento

Foram definidos três pipelines independentes:

GaussianNB: VarianceThreshold, remoção de correlação ($|r| > 0,90$), StandardScaler e SMOTE no treino.

BernoulliNB: VarianceThreshold, remoção de correlação, Binarizer e SMOTE no treino.

ComplementNB: MinMaxScaler para intervalo $[0, 1]$ e SMOTE no treino.

3. Busca de Hiperparâmetros

Foram executados aproximadamente 30 experimentos por variante (90 no total), com validação cruzada estratificada de 5 folds. Espaços de busca: GaussianNB (var_smoothing), BernoulliNB (alpha, binarize) e ComplementNB (alpha, norm). Critério de seleção: **Recall** médio, com desempate por F1, ROC-AUC e menor desvio padrão do Recall.

4. Comparação entre variantes de Naive Bayes

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
GaussianNB	0.6054	0.5629	0.9550	0.7083	0.6733
BernoulliNB	0.6806	0.6304	0.8780	0.7339	0.7265
ComplementNB	0.5750	0.5426	0.9731	0.6967	0.7268

GaussianNB obteve recall médio de 0.955, F1 de 0.708 e ROC-AUC de 0.673. BernoulliNB obteve recall médio de 0.878, F1 de 0.734 e ROC-AUC de 0.727. ComplementNB obteve recall médio de 0.973, F1 de 0.697 e ROC-AUC de 0.727. **GaussianNB** assume distribuição normal dos atributos contínuos, sendo adequado quando variáveis apresentam comportamento aproximadamente gaussiano após padronização. **BernoulliNB** assume atributos binários, útil quando a presença ou ausência de características é mais informativa que sua magnitude. **ComplementNB** é derivado do MultinomialNB e tende a ser mais robusto em cenários com desbalanceamento de classes, ao modelar complementarmente a probabilidade das classes. Empiricamente, **ComplementNB** apresentou o melhor recall médio (0.973) entre as variantes testadas, indicando que sua hipótese distributiva foi a mais compatível com o perfil do dataset de evasão — que combina atributos contínuos, categóricos codificados e proporções derivadas. O SMOTE aplicado apenas no treino de cada fold favoreceu a detecção da classe de alto risco sem contaminar a avaliação. Limitações permanecem na hipótese de independência condicional e na simplificação distributiva imposta por cada variante.

5. Melhor Configuração Encontrada

Modelo: ComplementNB
alpha: 0.16121212121212125
norm: True

6. Resultados do Modelo Final

Métrica	Média	Desvio Padrão
Accuracy	0.5750	0.0020
Precision	0.5426	0.0012
Recall	0.9731	0.0023
F1	0.6967	0.0013
ROC-AUC	0.7268	0.0074

O ComplementNB selecionado apresentou recall elevado, indicando boa capacidade de identificar cursos com alto risco de evasão. Com F1 médio de 0.697 e ROC-AUC médio de 0.727, o modelo final reflete o trade-off entre sensibilidade e precisão observado na comparação entre variantes.