

Relatório de Experimentação — Redes Neurais Artificiais

Predição de Risco de Evasão em Cursos de Educação Superior

João Pedro Barbosa Aragão
CIn – UFPE

17 de junho de 2026

Resumo

Este relatório documenta a experimentação com Redes Neurais Artificiais (RNA) para o problema de classificação binária de risco de evasão em cursos de educação superior, utilizando dados do Censo da Educação Superior 2024. Cinco arquiteturas foram avaliadas em *hold-out*, com e sem tratamento de desbalanceamento via *class weighting* e ajuste de limiar de decisão, estabelecendo um *baseline* de comparação entre os modelos. A arquitetura selecionada nessa fase — MLP de uma camada oculta treinada por *backpropagation* via SGD com momentum — foi então avaliada por validação cruzada 5-fold estratificada, com calibração do limiar de decisão realizada sem vazamento de informação entre os conjuntos de treino e validação, atendendo ao protocolo de avaliação estabelecido para a disciplina.

Sumário

1	Contextualização do Problema	3
2	Pré-processamento Aplicado nesta Fase	3
2.1	Análise de Importância de Atributos	3
2.2	Visualização via PCA	4
3	Arquiteturas de Redes Neurais Avaliadas	4
4	Resultados: Avaliação Inicial (<i>hold-out</i>, sem balanceamento)	5
4.1	Discussão dos Resultados Iniciais	5
5	Resultados: Balanceamento e Ajuste de Limiar (<i>hold-out</i>)	6
5.1	Motivação	6
5.2	Resultados com <i>Class Weighting</i> (threshold fixo 0,5)	6
5.3	Resultados: <i>Class Weighting</i> + Limiar Otimizado (<i>hold-out</i>)	7
5.4	Discussão: Interação entre <i>Class Weighting</i> e Threshold Tuning	7

6	Fronteiras de Decisão em Projeção PCA	8
7	Validação Cruzada 5-Fold do Modelo Selecionado	8
7.1	Protocolo Experimental	8
7.2	Resultados por Fold	9
7.3	Resultados Consolidados (Média $\pm$ Desvio-Padrão)	9
7.4	Discussão dos Resultados de Validação Cruzada	9
8	Síntese Comparativa e Justificativa Teórica	11

1 Contextualização do Problema

O problema endereçado é a classificação binária de cursos de graduação quanto ao risco de evasão, a partir de microdados do Censo da Educação Superior (INEP, 2024). A variável-alvo `ALTO_RISCO_EVASAO` é definida como:

$$\text{ALTO_RISCO_EVASAO} = \begin{cases} 1, & \text{se } \frac{\text{QT_SIT_DESVINCULADO} + \text{QT_SIT_TRANCADA}}{\text{QT_ING}} \geq 0,20 \\ 0, & \text{caso contrário} \end{cases} \quad (1)$$

A amostra de trabalho foi extraída por amostragem estratificada de 30.000 cursos (preservando a proporção original das classes) a partir de um universo de 720.349 cursos cadastrados, resultando em 21 atributos preditivos (8 categóricos e 13 numéricos, incluindo variáveis derivadas como taxa de conclusão, proporção EAD, proporção de financiamento estudantil, entre outras).

Desbalanceamento observado. A distribuição de classes na amostra é **24,6% (Baixo Risco)** contra **75,4% (Alto Risco)**, configurando um cenário de desbalanceamento moderado que motiva diretamente a estratégia de *class weighting* e ajuste de limiar adotada neste experimento.

2 Pré-processamento Aplicado nesta Fase

Para a etapa de Redes Neurais, foi utilizada uma combinação fixa de pré-processamento — e não a busca completa do pipeline de seleção de modelos — com o objetivo de isolar o efeito da arquitetura e das estratégias de balanceamento sobre o desempenho preditivo:

- **Tratamento de ausentes:** imputação pela moda (*mode imputation*) por coluna;
- **Codificação categórica:** *Label Encoding* para as 8 variáveis categóricas;
- **Escalonamento:** nenhum aplicado;
- **Particionamento (fase exploratória):** *hold-out* estratificado 80/20;
- **Particionamento (fase de validação):** *StratifiedKFold* com $K = 5$;
- **Seleção de atributos:** nenhuma removida; análise de importância (Random Forest e Informação Mútua) realizada em caráter exploratório.

2.1 Análise de Importância de Atributos

Como etapa exploratória prévia ao treinamento das redes, foi conduzida uma análise de importância de atributos via *Random Forest* e Informação Mútua (Tabela 1).

Tabela 1: Top 5 atributos por importância (Random Forest) e Informação Mútua

Atributo	Importância RF	Informação Mútua
RAZAO_ING_MAT	0,2333	0,1644
QT_MAT	0,1572	0,1155
QT_ING	0,1398	0,0733
CO_CINE_AREA_GERAL	0,1165	0,0064
TAXA_CONCLUSAO	0,0670	0,0517

A variável RAZAO_ING_MAT (razão entre ingressantes e matriculados) concentra a maior importância em ambas as métricas, o que é coerente com a definição do problema: cursos com alta rotatividade de ingressantes em relação ao corpo discente matriculado tendem a refletir diretamente o fenômeno de evasão.

2.2 Visualização via PCA

Uma projeção em duas componentes principais foi utilizada para inspeção visual da separabilidade das classes e posterior plotagem das fronteiras de decisão de cada arquitetura. As duas primeiras componentes explicam **91,83%** da variância total dos dados, justificando metodologicamente o uso dessa projeção para visualização qualitativa das fronteiras de decisão (Seção 6).

3 Arquiteturas de Redes Neurais Avaliadas

Foram implementadas e comparadas cinco arquiteturas, com complexidade crescente, de modo a investigar o efeito de não linearidade e profundidade sobre o desempenho preditivo. Todas foram implementadas em **TensorFlow/Keras**, com função de perda *binary crossentropy* e treinamento por 30 épocas (*batch size* = 32).

Tabela 2: Arquiteturas de Redes Neurais Avaliadas

Modelo	Arquitetura	Otimizador	Camadas
Perceptron (Linear)	1 neurônio (sigmoide)	Adam ($\eta = 10^{-3}$)	0
Perceptron Não-linear	10 neurônios (ReLU) → 1 (sigmoide)	Adam ($\eta = 10^{-2}$)	1
MLP 1 camada oculta	$n/2$ neurônios (ReLU) → 1 (sigmoide)	Adam ($\eta = 10^{-2}$)	1
MLP 2 camadas ocultas	$n/2$ (ReLU) → 3 (ReLU) → 1 (sigmoide)	Adam ($\eta = 10^{-2}$)	2
MLP 1 camada + SGD	$n/2$ (ReLU) → 1 (sigmoide)	SGD (momentum=0,9)	1

onde n é o número de atributos de entrada (21), resultando em 11 neurônios na camada oculta intermediária dos modelos MLP. A inclusão do **Perceptron Linear** como caso particular — equivalente, em capacidade representacional, a uma Regressão Logística — permite isolar o ganho atribuível exclusivamente à não linearidade introduzida pela camada oculta, enquanto a variante com **SGD + momentum** permite comparar o efeito do otimizador frente ao Adam, mantendo a arquitetura constante.

4 Resultados: Avaliação Inicial (*hold-out*, sem balanceamento)

A Tabela 3 apresenta os resultados da primeira rodada de experimentos, com limiar de decisão fixo em 0,5 e sem qualquer tratamento de desbalanceamento de classes.

Tabela 3: Desempenho no conjunto de teste (hold-out 20%) — sem balanceamento, threshold = 0,5

Modelo	Acurácia	F1-Score
Perceptron (Linear)	0,7540	0,8596
Perceptron Não-linear	0,8293	0,8897
MLP 1 camada oculta	0,8278	0,8866
MLP 2 camadas ocultas	0,8270	0,8846
MLP 1 camada + Backprop (SGD)	0,7542	0,8599

4.1 Discussão dos Resultados Iniciais

Três padrões emergem claramente desta primeira rodada:

1. **Efeito da não linearidade.** O salto de desempenho do Perceptron Linear (F1 = 0,8596) para o Perceptron Não-linear (F1 = 0,8897) — ambos otimizados com Adam — evidencia que a fronteira de decisão linear é insuficiente para capturar integralmente a relação entre os atributos (sobretudo `RAZAO_ING_MAT` e `QT_MAT`) e o risco de evasão. A introdução de uma única camada oculta com ativação ReLU já captura a maior parte do ganho não linear disponível.
2. **Diminishing returns de profundidade.** A adição de uma segunda camada oculta (MLP 2 camadas, F1 = 0,8846) não supera o MLP de 1 camada (F1 = 0,8866) nem o Perceptron Não-linear (F1 = 0,8897). Isso sugere que a complexidade do problema — relativamente tabular e de baixa dimensionalidade (21 atributos) — não demanda profundidade adicional, e que o aumento de parâmetros pode estar introduzindo ruído de otimização sem ganho representacional correspondente.
3. **Efeito do otimizador.** A comparação mais instrutiva é entre o **MLP 1 camada oculta (Adam)** e o **MLP 1 camada + Backprop (SGD)** — arquiteturas idênticas, otimizadores distintos. O modelo com SGD obtém desempenho próximo ao do

Perceptron Linear ($F1 = 0,8599$ vs. $0,8866$ do Adam), uma queda expressiva de quase 3 pontos percentuais de F1. Isso é consistente com a teoria de otimização: SGD com taxa de aprendizado fixa converge mais lentamente e é mais sensível à escala dos atributos do que otimizadores adaptativos como Adam, que ajustam a taxa de aprendizado por parâmetro. Como nenhum escalonamento foi aplicado nesta fase, o SGD provavelmente não teve tempo de convergência suficiente em 30 épocas para explorar a região não linear do espaço de pesos.

5 Resultados: Balanceamento e Ajuste de Limiar (*hold-out*)

5.1 Motivação

Como evidenciado na Seção 1, a classe positiva (Alto Risco) representa 75,4% da amostra. Em cenários de desbalanceamento, a acurácia bruta com limiar fixo em 0,5 tende a favorecer artificialmente a classe majoritária. Por esse motivo, foi adotada uma estratégia em duas etapas:

1. **Ponderação de classes** (*class weighting*) durante o treinamento, via `compute_class_weight('balanced')` do `scikit-learn`:

$$w_c = \frac{N}{K \cdot N_c} \quad (2)$$

onde N é o número total de amostras, K o número de classes e N_c o número de amostras da classe c . Os pesos obtidos no *hold-out* foram $w_0 = 2,033$ (Baixo Risco) e $w_1 = 0,663$ (Alto Risco).

2. **Ajuste de limiar de decisão** (*threshold tuning*), buscando exaustivamente, para cada modelo já treinado com pesos balanceados, o limiar $t \in \{0,10, 0,15, \dots, 0,85\}$ que maximiza o F1-score.

5.2 Resultados com *Class Weighting* (threshold fixo 0,5)

Tabela 4: Desempenho com class weighting — threshold fixo em 0,5

Modelo	Acurácia	F1-Score
Perceptron (Linear)	0,5943	0,6658
Perceptron Não-linear	0,7833	0,8391
MLP 1 camada oculta	0,7885	0,8442
MLP 2 camadas ocultas	0,8035	0,8593
MLP 1 camada + Backprop (SGD)	0,7982	0,8560

Como esperado teoricamente, a introdução do *class weighting* **reduz** as métricas calculadas com limiar fixo em 0,5 para todas as arquiteturas — de forma particularmente acentuada no Perceptron Linear (queda de 0,86 para 0,67 em F1). Isso ocorre porque o reponderamento desloca a fronteira de decisão implícita do modelo em favor da classe minoritária, fazendo com que o limiar de 0,5 — calibrado para a distribuição original — deixe de ser ótimo. Esse comportamento confirma que o balanceamento está de fato alterando a superfície de decisão do modelo, e justifica a necessidade da etapa de ajuste de limiar.

5.3 Resultados: *Class Weighting* + Limiar Otimizado (*hold-out*)

Tabela 5: Desempenho hold-out — class weighting + threshold otimizado por F1

Modelo	Limiar	Acurácia	F1	Precisão	Recall
Perceptron (Linear)	0,10	0,7540	0,8597	0,7541	0,9998
Perceptron Não-linear	0,20	0,8285	0,8882	0,8733	0,9036
MLP 1 camada oculta	0,20	0,8263	0,8890	0,8583	0,9220
MLP 2 camadas ocultas	0,25	0,8277	0,8889	0,8649	0,9143
MLP 1 camada + Backprop (SGD)	0,30	0,8335	0,8903	0,8846	0,8961

5.4 Discussão: Interação entre Class Weighting e Threshold Tuning

Os resultados da Tabela 5 revelam uma interação relevante entre as duas técnicas de tratamento de desbalanceamento:

Achado central: o ajuste de limiar **recupera** — e em alguns casos **supera** — o **desempenho obtido sem balanceamento** (Tabela 3), mas o faz de maneiras distintas para cada arquitetura, revelando que a combinação *class weighting + threshold tuning* interage de forma não trivial com a capacidade representacional do modelo.

1. **Perceptron Linear: caso degenerado e instrutivo.** Após o balanceamento e a busca de limiar, o Perceptron Linear migrou para um regime de limiar muito baixo ($t = 0,10$) e recall praticamente perfeito (0,9998), classificando como Alto Risco quase qualquer instância. A acurácia (0,7540) coincide exatamente com a proporção da classe majoritária na amostra, evidenciando que o modelo, em sua forma linear, não aprendeu uma fronteira de decisão informativa — apenas teve seu ponto de corte deslocado para o extremo onde o F1 é maximizado de forma quase trivial (alto recall compensando baixa precisão).
2. **Arquiteturas não lineares: ganho líquido sobre o cenário sem balanceamento.** As quatro arquiteturas com camada oculta voltaram, após o ajuste de limiar, a um F1 muito próximo (ou ligeiramente superior) ao obtido sem qualquer tratamento de desbalanceamento. O destaque é o **MLP 1 camada + Backprop (SGD)**, que evoluiu de F1 = 0,8599 (sem balanceamento) para F1 = 0,8903 — o **melhor resultado entre todas as configurações de hold-out testadas** — com a maior precisão

observada (0,8846). Isso indica que o SGD, que sofria com a convergência lenta na Seção 4.1, se beneficiou da reponderação dos gradientes durante o treino.

3. **Não linearidade como pré-requisito para o balanceamento ser eficaz.** A interação mais importante identificada é que **o ganho do threshold tuning é proporcional à capacidade não linear do modelo**. Em modelos lineares, deslocar o limiar apenas move ao longo de uma fronteira já fixa e pouco expressiva; em modelos não lineares, o reponderamento durante o treino efetivamente reformula a fronteira de decisão, e o ajuste de limiar posterior apenas calibra essa fronteira já mais rica para o objetivo de F1.

Com base nesses resultados de *hold-out*, a arquitetura **MLP 1 camada + Backprop (SGD)**, combinada a *class weighting* e ajuste de limiar, foi selecionada para a avaliação formal por validação cruzada exigida pelo critério de avaliação da disciplina.

6 Fronteiras de Decisão em Projeção PCA

Como suporte visual à discussão acima, as cinco arquiteturas foram re-treinadas exclusivamente sobre as duas componentes principais (PC1, PC2), permitindo a plotagem direta das fronteiras de decisão no plano. Esta análise é qualitativa — o desempenho numérico em 2D não é diretamente comparável ao obtido com as 21 features originais:

- O **Perceptron Linear** produz, como esperado teoricamente, uma fronteira estritamente linear (um hiperplano no espaço 2D).
- As arquiteturas com camada(s) oculta(s) e ativação ReLU produzem fronteiras compostas por segmentos lineares (consequência da natureza *piecewise linear* da ReLU), capazes de aproximar regiões de decisão não convexas.
- A complexidade visual da fronteira aumenta com o número de neurônios/camadas, mas — consistentemente com a Tabela 3 — o ganho em separabilidade visual entre o MLP de 1 e 2 camadas é marginal.

7 Validação Cruzada 5-Fold do Modelo Selecionado

7.1 Protocolo Experimental

Diferente da avaliação por *hold-out* (Seções 4–5), na qual o limiar de decisão foi calibrado diretamente sobre o próprio conjunto de teste, a validação cruzada formal exige um protocolo mais rigoroso para evitar vazamento de informação (*data leakage*). Buscar o limiar ótimo no mesmo fold usado para reportar a métrica final contaminaria a avaliação, pois o limiar estaria ajustado aos próprios dados sobre os quais o desempenho é medido.

Para corrigir esse ponto, cada um dos 5 folds estratificados (**StratifiedKFold**, $K = 5$) foi tratado internamente em três etapas:

1. O fold de treino é subdividido em **treino interno (80%)** e **calibração (20%)**, com estratificação preservada;
2. O modelo é treinado no treino interno, com pesos de classe (*class_weight*) calculados **exclusivamente a partir do treino interno** desse fold — e não da distribuição global do dataset;
3. O limiar de decisão é otimizado por busca em grade ($t \in \{0,10, \dots, 0,85\}$, passo 0,05) **no conjunto de calibração**, e só então aplicado, já fixo, ao fold de validação para o cálculo das métricas finais.

Por que esse detalhe importa. Esse protocolo garante que o fold de validação de cada iteração nunca seja usado para nenhuma decisão de tuning — nem do modelo, nem do limiar — preservando a validade estatística da estimativa de desempenho fora da amostra (*out-of-sample*), em conformidade com a exigência de cross-validation 5-fold do critério de avaliação.

7.2 Resultados por Fold

Tabela 6: Desempenho do MLP 1 camada + Backprop (SGD) em cada um dos 5 folds

Fold	Limiar	Acurácia	F1	Precisão	Recall
1	0,10	0,7542	0,8599	0,7542	1,0000
2	0,20	0,8245	0,8865	0,8650	0,9092
3	0,20	0,8218	0,8873	0,8482	0,9302
4	0,25	0,8218	0,8853	0,8600	0,9122
5	0,25	0,8300	0,8908	0,8639	0,9193

7.3 Resultados Consolidados (Média $\pm$ Desvio-Padrão)

Tabela 7: Desempenho consolidado — MLP 1 camada + Backprop (SGD), 5-fold CV

Métrica	Média $\pm$ Desvio-Padrão
Acurácia	0,8105 $\pm$ 0,0283
F1-Score	0,8820 $\pm$ 0,0112
Precisão	0,8383 $\pm$ 0,0425
Recall	0,9342 $\pm$ 0,0337
Limiar médio	0,200 $\pm$ 0,055

7.4 Discussão dos Resultados de Validação Cruzada

1. **Comparação com o hold-out original.** O F1 médio da validação cruzada (0,8820) é levemente inferior ao observado no hold-out único (0,8903, Tabela 5), uma diferença

de apenas 0,83 ponto percentual. Essa proximidade é um indício positivo de que o resultado do hold-out não foi um artefato de uma partição de teste particularmente favorável, e que o desempenho do modelo é razoavelmente estável sob diferentes amostragens dos dados.

2. **O Fold 1 reproduz o caso degenerado do Perceptron Linear.** O resultado mais instrutivo da validação cruzada é o comportamento do **Fold 1**: o limiar calibrado convergiu para 0,10 — o valor mínimo da grade de busca — produzindo recall de 100% e a menor acurácia entre os 5 folds (0,7542, novamente coincidindo com a proporção aproximada da classe majoritária). Isso significa que, para a partição específica de dados sorteada nesse fold, o modelo (mesmo sendo não linear) convergiu para uma solução que prioriza recall quase absoluto à custa de precisão, o mesmo padrão observado anteriormente no Perceptron Linear do hold-out (Tabela 5). Esse achado é relevante: evidencia que a convergência do SGD é sensível à inicialização e à partição de treino/calibração, podendo ocasionalmente reproduzir uma fronteira de decisão pouco informativa mesmo numa arquitetura com capacidade não linear — um lembrete de que a média sobre múltiplos folds é precisamente o que permite identificar e diluir esse tipo de instabilidade, que passaria despercebida numa avaliação de hold-out único.
3. **Maior variância em precisão do que em F1 e acurácia.** O desvio-padrão da precisão (0,0425) é proporcionalmente o maior entre as quatro métricas (coeficiente de variação $\approx 5,7\%$, contra $\approx 1,4\%$ do F1). Isso é coerente com o item anterior: como o limiar ótimo variou entre 0,10 e 0,25 ao longo dos folds, e limiares mais baixos sacrificam precisão em favor de recall, a métrica de precisão é naturalmente mais sensível a essa variação de limiar entre folds do que o F1 — que, por ser a métrica que o próprio threshold tuning otimiza, tende a se manter mais estável independentemente do ponto de corte escolhido em cada fold.
4. **Recall consistentemente alto.** O recall médio (0,9342) é a métrica com maior valor absoluto entre as quatro, em todos os folds acima de 0,90. Para o problema de evasão, isso é um resultado favorável sob a perspectiva de política educacional: o modelo erra mais frequentemente por excesso de alerta (falsos positivos, reduzindo a precisão) do que por omissão (falsos negativos, que reduziriam o recall) — um perfil de erro preferível quando o custo de não identificar um curso em risco supera o custo de uma intervenção preventiva desnecessária.

8 Síntese Comparativa e Justificativa Teórica

Tabela 8: Síntese: evolução do F1-Score por arquitetura/protocolo

Configuração	F1-Score
Sem balanceamento (hold-out)	0,8599
Class weighting, threshold fixo 0,5 (hold-out)	0,8560
Class weighting + threshold ótimo (hold-out)	0,8903
Class weighting + threshold calibrado sem leakage (5-fold CV)	$0,8820 \pm 0,0112$

A leitura da Tabela 8 resume o argumento central deste relatório: a queda de desempenho observada com *class weighting* e threshold fixo é transitória e esperada, sendo revertida pelo ajuste de limiar. A validação cruzada confirma que esse ganho não é um artefato do hold-out específico utilizado — o F1 médio sob um protocolo metodologicamente mais rigoroso (limiar calibrado sem acesso aos dados de validação) permanece próximo ao valor obtido no hold-out, com uma queda pequena e esperada decorrente da ausência de otimismo de avaliação (a calibração não "vê" os dados de teste).

Modelo selecionado para a comparação final entre algoritmos da disciplina: MLP 1 camada oculta + Backprop (SGD), com class weighting e threshold calibrado por fold, reportando $F1 = 0,8820 \pm 0,0112$, Acurácia = $0,8105 \pm 0,0283$, Precisão = $0,8383 \pm 0,0425$ e Recall = $0,9342 \pm 0,0337$ sob protocolo de validação cruzada 5-fold.