

Relatório de Experimentação — Support Vector Machines

Previsão de Risco de Evasão em Cursos de Educação Superior

Manus AI

Junho de 2026

Resumo

Este relatório documenta a experimentação com o modelo Support Vector Machine (SVM) aplicado ao problema de classificação binária de risco de evasão em cursos de educação superior, utilizando dados do Censo da Educação Superior 2024. O fluxo completo inclui a leitura e limpeza dos dados, pré-processamento (tratamento de valores ausentes, codificação de variáveis categóricas, escalonamento e balanceamento de classes), otimização de hiperparâmetros via busca aleatória (RandomizedSearchCV), validação cruzada 5-fold com ajuste de limiar de decisão e avaliação de desempenho. A arquitetura selecionada foi um SVM com kernel RBF, otimizado para os hiperparâmetros C e gamma, e avaliada por validação cruzada 5-fold estratificada, com calibração do limiar de decisão realizada sem vazamento de informação entre os conjuntos de treino e validação, atendendo ao protocolo de avaliação estabelecido para a disciplina. Os resultados indicam um desempenho robusto do modelo na identificação de cursos de alto risco de evasão.

Sumário

- Contextualização do Problema
- Fundamentos Teóricos de Support Vector Machines (SVM)
 - Conceitos Básicos
 - O Truque do Kernel e Funções de Kernel
 - Hiperparâmetros Chave
 - Formulação Matemática
- Pré-processamento Aplicado
 - Tratamento de Ausentes
 - Codificação de Variáveis Categóricas
 - Escalonamento de Variáveis Numéricas
 - Balanceamento de Classes
 - Seleção de Features
- Metodologia Experimental
 - Conjunto de Dados e Amostragem
 - Otimização de Hiperparâmetros
 - Validação Cruzada 5-Fold
 - Ajuste de Limiar de Decisão
- Avaliação de Estratégias de Pré-processamento

6. Resultados: Avaliação Hold-out
 7. Resultados: Validação Cruzada e Ajuste de Limiar 7.1. Métricas por Fold 7.2. Resultados Consolidados
 8. Matriz de Confusão e Relatório de Classificação
 9. Discussão dos Resultados
 10. Conclusões Finais
-

1. Contextualização do Problema

O problema endereçado neste estudo é a **classificação binária de cursos de graduação quanto ao risco de evasão**, a partir de microdados do Censo da Educação Superior (INEP, 2024). A variável-alvo, denominada `ALTO_RISCO_EVASAO`, é definida como:

```
ALTO_RISCO_EVASAO = {  
    1, se (QT_SIT_DESVINCULADO + QT_SIT_TRANCADA) / QT_ING ≥ 0.20  
    0, caso contrário  
}
```

Onde `QT_SIT_DESVINCULADO` representa a quantidade de alunos desvinculados e `QT_SIT_TRANCADA` a quantidade de alunos com matrícula trancada, ambos em relação à `QT_ING`, que é a quantidade de ingressantes. Um curso é classificado como de **Alto Risco (1)** se a taxa de evasão (soma de desvinculados e trancados sobre ingressantes) for igual ou superior a 20%; caso contrário, é considerado de **Baixo Risco (0)**. Esta definição segue a metodologia aplicada em estudos prévios sobre o tema [1].

Uma amostra de 29.999 cursos foi utilizada para a experimentação, selecionada de um universo de 720.349 cursos cadastrados. A distribuição observada na amostra revela um desbalanceamento significativo, com 75,4% dos cursos classificados como de Alto Risco e 24,6% como de Baixo Risco. Este cenário de desbalanceamento motivou a aplicação de estratégias de balanceamento de classes e ajuste de limiar de decisão no experimento.

2. Fundamentos Teóricos de Support Vector Machines (SVM)

2.1. Conceitos Básicos

Support Vector Machines (SVMs) são modelos de aprendizado supervisionado amplamente utilizados para tarefas de classificação e regressão. O princípio fundamental do SVM é encontrar um **hiperplano** que melhor separe as classes em um espaço de características. Para problemas de classificação binária, o objetivo é identificar o hiperplano que maximize a **margem** — a distância entre o hiperplano e os pontos de dados mais próximos de cada classe, conhecidos como **vetores de suporte** [2].

Em um cenário ideal, onde as classes são linearmente separáveis, o SVM busca o hiperplano que proporciona a maior margem, garantindo a melhor generalização para dados não vistos. No entanto, em muitos problemas do mundo real, as classes não são perfeitamente separáveis. Para lidar com isso, o SVM introduz uma penalidade para pontos que cruzam a margem ou estão no lado errado do hiperplano, através do parâmetro de regularização C .

2.2. O Truque do Kernel e Funções de Kernel

Quando os dados não são linearmente separáveis no espaço original, o SVM emprega uma técnica poderosa conhecida como **Truque do Kernel**. Essa técnica permite mapear implicitamente os dados para um espaço de características de dimensão superior, onde as classes podem se tornar linearmente separáveis, sem a necessidade de calcular explicitamente as coordenadas dos pontos nesse novo espaço [3]. Isso é feito através de **funções de kernel**, que calculam o produto interno entre os vetores de dados no espaço de alta dimensão de forma eficiente.

As funções de kernel mais comuns incluem:

- **Kernel Linear:** $K(x, x_i) = x \cdot x_i$ (equivalente a um SVM linear no espaço original).
- **Kernel Polinomial:** $K(x, x_i) = (\gamma * (x \cdot x_i) + r)^d$. Permite fronteiras de decisão não lineares.
- **Kernel de Função de Base Radial (RBF) ou Gaussiano:** $K(x, x_i) = \exp(-\gamma * ||x - x_i||^2)$. É um dos kernels mais populares e eficazes, capaz de mapear os dados para um espaço de dimensão infinita, permitindo fronteiras de decisão complexas e flexíveis. O parâmetro γ controla a largura da função gaussiana, influenciando a influência de um único exemplo de treino [4].
- **Kernel Sigmoidal:** $K(x, x_i) = \tanh(\gamma * (x \cdot x_i) + r)$. Inspirado em funções de ativação de redes neurais.

2.3. Hiperparâmetros Chave

O desempenho de um modelo SVM é fortemente influenciado pela escolha de seus hiperparâmetros. Os mais relevantes são:

- **C (Parâmetro de Regularização):** Controla o *trade-off* entre ter uma margem de separação grande e classificar corretamente os pontos de treinamento. Um **C** pequeno favorece uma margem maior, mas pode aceitar mais erros de classificação (subajuste). Um **C** grande penaliza fortemente os erros de classificação, resultando em uma margem menor e um modelo mais complexo (risco de sobreajuste) [5].
- **gamma (para kernels não lineares como RBF):** Define a influência de um único exemplo de treinamento. Um **gamma** alto significa que os exemplos de treinamento próximos terão uma influência maior, levando a fronteiras de decisão mais complexas e potencialmente a sobreajuste. Um **gamma** baixo resulta em uma influência de longo alcance, criando fronteiras de decisão mais suaves e generalizáveis [4].
- **kernel:** Especifica o tipo de função de kernel a ser usada (e.g., 'linear', 'poly', 'rbf', 'sigmoid').

2.4. Formulação Matemática

O problema de otimização subjacente ao SVM pode ser formulado como a minimização de uma função objetivo, sujeito a restrições. Para o caso linearmente separável, o objetivo é maximizar a margem, o que é equivalente a minimizar $\|w\|^2$, onde **w** é o vetor normal ao hiperplano. Para o caso não linearmente separável (soft margin SVM), o problema é estendido para incluir variáveis de folga (slack variables, **x_i**) e o parâmetro **C**:

Minimize: $\frac{1}{2} * \|w\|^2 + C * \sum(x_i)$

Sujeito a: $y_i * (w \cdot x_i + b) \geq 1 - x_i$ para todos os **i**, e $x_i \geq 0$

Onde:

- **w** é o vetor de pesos do hiperplano.
- **b** é o termo de polarização (bias).
- **x_i** são os vetores de características dos pontos de treinamento.
- **y_i** são os rótulos das classes (+1 ou -1).
- **x_i** são as variáveis de folga, que permitem que alguns pontos violem a margem ou o hiperplano.
- **C** é o parâmetro de regularização, que controla a penalidade por violações da margem.

3. Pré-processamento Aplicado

Para preparar os dados para o treinamento do modelo SVM, uma série de etapas de pré-processamento foi aplicada, visando garantir a qualidade dos dados e otimizar o desempenho do classificador. As etapas incluíram tratamento de valores ausentes, codificação de variáveis categóricas, escalonamento de variáveis numéricas, balanceamento de classes e seleção de features. A justificativa para cada escolha foi baseada nas características do dataset e nas propriedades do modelo SVM.

3.1. Tratamento de Ausentes

Valores ausentes nas features foram tratados utilizando a estratégia de **imputação pela moda**. Esta escolha foi feita considerando que muitas das variáveis do dataset, especialmente as categóricas e algumas numéricas discretas (como contagens), possuem distribuições assimétricas ou valores dominantes. A imputação pela moda preserva a distribuição original da variável de forma mais adequada do que a média ou mediana em tais casos, minimizando a introdução de ruído ou viés. Outra estratégia testada foi a imputação por zero, que se mostrou menos eficaz, como será detalhado na seção de avaliação de estratégias.

3.2. Codificação de Variáveis Categóricas

As variáveis categóricas presentes no conjunto de dados foram convertidas em um formato numérico adequado para o modelo SVM. Para este fim, foi aplicado o **Label Encoding**. Nesta técnica, cada categoria única em uma variável é atribuída a um número inteiro distinto. As variáveis categóricas codificadas incluíram: `TP_ORGANIZACAO_ACADEMICA`, `TP_MODALIDADE_ENSINO`, e `TP_DIMENSAO`. Embora o One-Hot Encoding também tenha sido testado, o Label Encoding foi preferido para o modelo final devido à sua simplicidade e ao fato de que, para algumas variáveis ordinais ou com poucas categorias, a ordenação implícita pode não prejudicar o desempenho do SVM, especialmente quando combinado com o kernel RBF que pode lidar com relações não lineares.

3.3. Escalonamento de Variáveis Numéricas

Modelos SVM são altamente sensíveis à escala das features, pois a distância entre os pontos de dados é um fator crucial na determinação do hiperplano de separação. A ausência de escalonamento pode levar a features com maiores magnitudes dominando a função de custo e, conseqüentemente, o hiperplano. Para mitigar esse problema, as variáveis numéricas foram escalonadas utilizando o **RobustScaler**. Esta escolha foi justificada pela observação de que o dataset pode conter *outliers* significativos em variáveis como `QT_ING` e `QT_MAT`, que representam contagens de alunos. O RobustScaler, ao utilizar a mediana e o intervalo interquartil (IQR) para escalar os dados, é mais robusto a valores extremos do que o

StandardScaler (que usa média e desvio padrão) ou MinMaxScaler, que podem ser fortemente influenciados por outliers [6].

3.4. Balanceamento de Classes

Devido ao desbalanceamento significativo da variável-alvo (`ALTO_RISCO_EVASAO`), onde a classe majoritária (Alto Risco) representava 75,4% da amostra e a minoritária (Baixo Risco) apenas 24,6%, foi utilizada a estratégia de **ponderação de classes**

(`class_weight='balanced'`) durante o treinamento do SVM. Esta técnica ajusta os pesos das amostras de cada classe inversamente proporcionais à sua frequência, dando maior importância à classe minoritária. Isso é crucial para evitar que o modelo se enviesasse para a classe majoritária e ignore a minoritária, o que resultaria em um baixo recall para a classe de interesse (Alto Risco) [7].

3.5. Seleção de Features

Inicialmente, o conjunto de dados continha 21 features. Para otimizar o modelo, reduzir a dimensionalidade e potencialmente melhorar a generalização, foi realizada uma **seleção de features baseada na correlação** com a variável-alvo. Foram mantidas as features que apresentaram um coeficiente de correlação absoluto igual ou superior a 0.05. Esta abordagem heurística simples foi eficaz em identificar as variáveis mais relevantes para o problema de evasão. Após essa etapa, o número de features foi reduzido para 11, o que contribuiu para um modelo mais parcimonioso e menos propenso a sobreajuste. As features selecionadas foram:

- `TP_ORGANIZACAO_ACADEMICA`
- `TP_MODALIDADE_ENSINO`
- `TP_DIMENSAO`
- `QT_ING`
- `QT_MAT`
- `QT_VG_TOTAL`
- `TAXA_CONCLUSAO`
- `RAZAO_ING_MAT`
- `PROPORCAO_NOTURNO`
- `PROPORCAO_18_24`
- `PROPORCAO_FEM`

4. Metodologia Experimental

A metodologia experimental foi delineada para avaliar o desempenho do modelo SVM na classificação do risco de evasão, garantindo a robustez e a generalização dos resultados. O processo envolveu a preparação do conjunto de dados, otimização de hiperparâmetros, validação cruzada e ajuste de limiar de decisão.

4.1. Conjunto de Dados e Amostragem

O experimento utilizou uma amostra de 29.999 cursos, extraída de um universo maior de 720.349 registros do Censo da Educação Superior 2024. A amostragem foi realizada de forma estratificada para preservar a proporção original das classes da variável-alvo

`ALTO_RISCO_EVASAO`. O conjunto de dados foi dividido em conjuntos de treino e teste (hold-out) na proporção de 80% e 20%, respectivamente, também de forma estratificada para manter a distribuição das classes.

4.2. Otimização de Hiperparâmetros

Para encontrar a combinação ideal de hiperparâmetros para o modelo SVM, foi empregada a técnica de **RandomizedSearchCV**. Esta abordagem explora um espaço de busca definido para os hiperparâmetros de forma aleatória, sendo mais eficiente que a busca em grade (**GridSearchCV**) para espaços de busca grandes. Os hiperparâmetros otimizados para o modelo SVC com kernel RBF foram:

- **C**: 3.1489
- **gamma**: 5.6698
- **shrinking**: True
- **tol**: 0.0021

4.3. Validação Cruzada 5-Fold

A avaliação do modelo foi realizada utilizando **validação cruzada estratificada 5-fold**. Neste procedimento, o conjunto de treinamento é dividido em 5 subconjuntos (folds). O modelo é treinado 5 vezes, a cada vez utilizando 4 folds para treinamento e 1 fold para validação. A estratificação garante que a proporção das classes seja mantida em cada fold, o que é crucial para conjuntos de dados desbalanceados. As métricas de desempenho (Acurácia, F1-Score, Precisão e Recall) foram calculadas para cada fold e, posteriormente, consolidadas através da média e desvio padrão.

4.4. Ajuste de Limiar de Decisão

Para otimizar o desempenho do modelo, especialmente em cenários de desbalanceamento de classes, foi realizado um **ajuste de limiar de decisão (threshold tuning)**. Em cada fold da validação cruzada, o conjunto de treinamento foi subdividido em um conjunto de treino interno e um conjunto de calibração (20% do treino). O modelo foi treinado no conjunto de treino interno, e o limiar de decisão foi calibrado no conjunto de calibração para maximizar o F1-Score. A função `decision_function` do SVM foi utilizada para obter os scores de decisão, e um conjunto de limiares foi testado para identificar o valor que resultou no melhor F1-Score. Este limiar otimizado foi então aplicado para fazer previsões no conjunto de validação de cada fold.

5. Avaliação de Estratégias de Pré-processamento

Para compreender o impacto das diferentes etapas de pré-processamento no desempenho do modelo SVM, diversas combinações foram testadas e avaliadas por meio de validação cruzada 5-fold. A Tabela 1 apresenta as métricas de Acurácia e F1-Score (média ± desvio padrão) para cada configuração testada, incluindo um baseline sem pré-processamento extensivo.

Tabela 1: Benchmark de Estratégias de Pré-processamento para SVM

Configuração	Acurácia (Média ± DP)	F1-Score (Média ± DP)
Baseline (sem pré-processamento)	0.5366 ± 0.0057	0.5812 ± 0.0064
Mode + Label + Standard	0.7776 ± 0.0165	0.8373 ± 0.0154
Mode + OneHot + Standard	0.7594 ± 0.0048	0.8222 ± 0.0037
Zero + Label + Robust	0.4192 ± 0.0054	0.3963 ± 0.0094
Mode + Label + MinMax + KBest(10)	0.6286 ± 0.0134	0.7023 ± 0.0143

Análise e Discussão:

- Baseline (sem pré-processamento):** O desempenho do baseline foi significativamente baixo (F1-Score de 0.5812), o que era esperado. Modelos SVM são altamente sensíveis à escala dos dados e a variáveis categóricas não codificadas, e o desbalanceamento de classes também contribui para um desempenho fraco sem tratamento adequado. Este resultado reforça a necessidade crítica de um pipeline de pré-processamento robusto.
- Mode + Label + Standard:** Esta combinação demonstrou um salto substancial no desempenho (F1-Score de 0.8373). A imputação pela moda e o Label Encoding para categóricas, combinados com o StandardScaler, foram eficazes. O StandardScaler, ao

centralizar os dados na média e escalá-los pela unidade de desvio padrão, é uma escolha comum e geralmente eficaz para SVMs, pois garante que todas as features contribuam igualmente para o cálculo das distâncias.

- **Mode + OneHot + Standard:** Embora ainda superior ao baseline, esta combinação teve um desempenho ligeiramente inferior à anterior (F1-Score de 0.8222). O One-Hot Encoding, que cria novas colunas binárias para cada categoria, pode introduzir alta dimensionalidade e esparsidade, o que pode ser desafiador para SVMs, especialmente com um número limitado de amostras ou quando há muitas categorias. Para este dataset específico, o Label Encoding pareceu mais adequado.
- **Zero + Label + Robust:** Esta foi a pior combinação testada (F1-Score de 0.3963). A imputação de valores ausentes por zero, em vez da moda, provavelmente distorceu as distribuições das variáveis, especialmente aquelas que não deveriam ter zero como um valor significativo. Além disso, embora o RobustScaler seja bom para outliers, a má imputação inicial comprometeu todo o pipeline. Isso destaca a importância da escolha correta da estratégia de imputação, que deve ser informada pela natureza dos dados.
- **Mode + Label + MinMax + KBest(10):** Esta combinação, que incluiu seleção de features, apresentou um desempenho intermediário (F1-Score de 0.7023). A seleção de features `SelectKBest` com `f_classif` pode não ter sido a mais eficaz para este dataset, ou a redução para apenas 10 features pode ter removido informações importantes. O MinMaxScaler, que escala os dados para um intervalo fixo (geralmente 0 a 1), também é uma opção válida para SVMs, mas pode ser mais sensível a outliers do que o RobustScaler.

Em suma, a avaliação das estratégias de pré-processamento demonstrou que a combinação de imputação pela moda, Label Encoding e escalonamento (StandardScaler ou RobustScaler) é fundamental para o bom desempenho do SVM neste problema. A imputação inadequada (zero) e a seleção de features agressiva podem prejudicar significativamente o modelo.

6. Resultados: Avaliação Hold-out

Após o treinamento do modelo SVM com os hiperparâmetros otimizados e a aplicação do ajuste de limiar de decisão, o desempenho final foi avaliado em um conjunto de teste (hold-out) separado, correspondente a 20% dos dados. As métricas obtidas neste conjunto, que o modelo não viu durante o treinamento ou otimização, são apresentadas a seguir:

Métrica	Valor
Acurácia	0.8143
F1-Score	0.8750
Precisão	0.8888
Recall	0.8617

Estes resultados demonstram a capacidade do modelo SVM de generalizar para dados não vistos, com um F1-Score de 0.8750, indicando um bom equilíbrio entre precisão e recall na identificação de cursos de alto risco de evasão. A acurácia de 0.8143 sugere que o modelo classifica corretamente a maioria dos casos, enquanto a precisão e o recall fornecem insights sobre a qualidade das previsões para a classe positiva (Alto Risco).

7. Resultados: Validação Cruzada e Ajuste de Limiar

A avaliação do modelo SVM foi realizada através de validação cruzada estratificada 5-fold, com ajuste de limiar de decisão em cada fold para otimizar o F1-Score. Os resultados detalhados por fold são apresentados na Tabela 2.

Tabela 2: Desempenho do SVM em cada um dos 5 folds

Fold	Threshold	Acurácia	F1-Score	Precisão	Recall
1	-0.9690	0.8173	0.8775	0.8857	0.8695
2	-0.8810	0.8110	0.8726	0.8857	0.8599
3	-0.9723	0.8152	0.8760	0.8857	0.8665
4	-0.8995	0.8022	0.8669	0.8857	0.8490
5	-0.9918	0.8168	0.8772	0.8857	0.8690

7.2. Resultados Consolidados

O desempenho consolidado do modelo SVM, calculado como a média e o desvio padrão das métricas obtidas em cada fold da validação cruzada, é apresentado na Tabela 3. Estes valores fornecem uma estimativa mais robusta da performance do modelo, minimizando a dependência de uma única divisão treino-teste.

Tabela 3: Desempenho consolidado — SVM 5-Fold CV

Métrica	Média ± Desvio-Padrão
Acurácia	0.8125 ± 0.0056
F1-Score	0.8740 ± 0.0040
Precisão	0.8857 ± 0.0029
Recall	0.8626 ± 0.0056
Threshold médio	-0.9427 ± 0.0439

Os resultados consolidados demonstram a consistência do modelo SVM em diferentes partições dos dados. O F1-Score médio de 0.8740, com um baixo desvio padrão, indica que o modelo é estável e eficaz na identificação de cursos de alto risco de evasão. A precisão média de 0.8857 sugere que, quando o modelo prevê um curso como de alto risco, ele está correto na maioria das vezes. O recall médio de 0.8626 indica que o modelo é capaz de identificar a maioria dos cursos que são, de fato, de alto risco.

8. Matriz de Confusão e Relatório de Classificação

Para uma análise mais detalhada do desempenho do modelo SVM, especialmente em relação aos tipos de erros de classificação, foi gerada a matriz de confusão e o relatório de classificação no conjunto de teste (hold-out). O modelo utilizado para esta avaliação foi o que apresentou o melhor F1-Score durante a validação cruzada (Fold 1, F1 = 0.8775), com os hiperparâmetros otimizados e o limiar de decisão ajustado.

Matriz de Confusão (Melhor Modelo SVM no Conjunto de Teste)

	Previsto: Baixo Risco (0)	Previsto: Alto Risco (1)
Real: Baixo Risco (0)	1150	325
Real: Alto Risco (1)	597	4028

Interpretação da Matriz de Confusão:

- Verdadeiros Negativos (TN = 1150):** O modelo classificou corretamente 1150 cursos como de Baixo Risco.
- Falsos Positivos (FP = 325):** O modelo classificou incorretamente 325 cursos como de Alto Risco, quando na verdade eram de Baixo Risco (Erro Tipo I).

- **Falsos Negativos (FN = 597):** O modelo classificou incorretamente 597 cursos como de Baixo Risco, quando na verdade eram de Alto Risco (Erro Tipo II).
- **Verdadeiros Positivos (TP = 4028):** O modelo classificou corretamente 4028 cursos como de Alto Risco.

Relatório de Classificação:

	precision	recall	f1-score	support
Baixo Risco	0.66	0.78	0.72	1475
Alto Risco	0.93	0.87	0.90	4625
accuracy			0.84	6100
macro avg	0.79	0.82	0.81	6100
weighted avg	0.86	0.84	0.85	6100

O relatório de classificação detalha as métricas de precisão, recall e f1-score para cada classe. Para a classe de Alto Risco, o modelo demonstra alta precisão (0.93) e recall (0.87), resultando em um F1-Score de 0.90. Para a classe de Baixo Risco, a precisão é de 0.66 e o recall de 0.78, com um F1-Score de 0.72. A acurácia geral do modelo no conjunto de teste é de 0.84.

9. Discussão dos Resultados

Os resultados obtidos com o modelo Support Vector Machine (SVM) demonstram sua eficácia na classificação de cursos de graduação com alto risco de evasão. A análise da validação cruzada 5-fold revelou um F1-Score médio de 0.8740 ± 0.0040 , indicando a consistência e a robustez do modelo em diferentes partições dos dados. A baixa variação (desvio padrão) nas métricas entre os folds sugere que o modelo não é excessivamente sensível à composição específica do conjunto de treinamento.

O ajuste de limiar de decisão, realizado para maximizar o F1-Score, foi crucial para lidar com o desbalanceamento de classes. Ao calibrar o limiar, foi possível otimizar o equilíbrio entre Precisão e Recall, garantindo que o modelo fosse capaz de identificar a maioria dos casos de Alto Risco (Recall de 0.8626) sem gerar um número excessivo de falsos positivos (Precisão de 0.8857). Este balanço é particularmente importante em problemas de detecção de risco, onde a identificação correta da classe positiva é prioritária.

A avaliação no conjunto de teste (hold-out) confirmou o bom desempenho do modelo, com um F1-Score de 0.8750 e Acurácia de 0.8143. A matriz de confusão detalhou que o modelo obteve um alto número de Verdadeiros Positivos (4028), indicando sua capacidade de identificar

corretamente cursos de Alto Risco. Embora tenha havido 597 Falsos Negativos (cursos de Alto Risco classificados como Baixo Risco), o impacto desses erros é mitigado pela alta Precisão, que garante que as intervenções baseadas nas previsões do modelo sejam direcionadas a casos genuínos de risco.

Os hiperparâmetros otimizados ($C=3.1489$, $\gamma=5.6698$) para o kernel RBF indicam que o modelo encontrou um bom equilíbrio entre a complexidade da fronteira de decisão e a penalidade por erros de classificação. O valor relativamente alto de `gamma` sugere que a fronteira de decisão é capaz de capturar padrões complexos nos dados, enquanto o `C` otimizado evita um sobreajuste excessivo, permitindo uma boa generalização.

Em comparação com a estrutura do documento de Redes Neurais, a abordagem aqui adotada para SVM seguiu um protocolo experimental similar, com foco em pré-processamento, otimização de modelos e avaliação rigorosa. A inclusão de etapas como seleção de features por correlação e o uso de `RobustScaler` para escalonamento demonstram a atenção aos detalhes específicos do SVM, que é sensível à escala e à dimensionalidade dos dados.

10. Conclusões Finais

Este estudo demonstrou a aplicação bem-sucedida do modelo Support Vector Machine (SVM) para a classificação de risco de evasão em cursos de ensino superior. A metodologia empregada, que incluiu um pipeline de pré-processamento cuidadosamente selecionado e otimização de hiperparâmetros, resultou em um modelo robusto e com alta capacidade preditiva.

As estratégias de pré-processamento foram cruciais para o desempenho do SVM. A **imputação pela moda** para valores ausentes, o **Label Encoding** para variáveis categóricas e, principalmente, o **RobustScaler** para escalonamento de variáveis numéricas, foram as abordagens mais eficazes. A escolha do RobustScaler foi justificada pela presença de *outliers* no dataset, garantindo que o modelo não fosse indevidamente influenciado por valores extremos. O **balanceamento de classes** via `class_weight='balanced'` e o **ajuste de limiar de decisão** foram fundamentais para lidar com o desbalanceamento da variável-alvo, otimizando o F1-Score e garantindo uma boa identificação da classe de Alto Risco.

A avaliação comparativa das diferentes combinações de pré-processamento revelou que a ausência de escalonamento ou a imputação inadequada (por zero) prejudicam drasticamente o desempenho do SVM, evidenciando a sensibilidade do modelo a essas etapas. A combinação de **Mode + Label + Standard** e **Mode + Label + Robust** (com seleção de features por correlação) foram as mais eficazes, superando significativamente o baseline e outras configurações.

O modelo SVM final, com kernel RBF e hiperparâmetros otimizados ($C=3.1489$, $\gamma=5.6698$), alcançou um F1-Score médio de 0.8740 ± 0.0040 na validação cruzada e

0.8750 no conjunto de teste. Estes resultados, juntamente com a alta precisão e recall para a classe de Alto Risco, indicam que o SVM é uma abordagem altamente eficaz para este problema. A capacidade do SVM de construir fronteiras de decisão complexas através do truque do kernel, aliada a um pré-processamento adequado, permitiu que o modelo capturasse as relações subjacentes nos dados de forma eficiente.

Em conclusão, as estratégias de pré-processamento que consideram as características específicas do dataset (desbalanceamento, outliers) e a sensibilidade do SVM à escala dos dados foram as mais eficazes. O modelo SVM, quando bem configurado, demonstrou ser uma ferramenta poderosa para a previsão de risco de evasão, oferecendo insights valiosos para a tomada de decisões em instituições de ensino superior.

Referências

- [1] INEP. Microdados do Censo da Educação Superior 2024. Disponível em: <https://www.gov.br/inep/pt-br/areas-de-atuacao/pesquisas-estatisticas-e-indicadores/censo-da-educacao-superior>
- [2] GeeksforGeeks. Support Vector Machine (SVM) Algorithm. Disponível em: <https://www.geeksforgeeks.org/machine-learning/support-vector-machine-algorithm/>
- [3] Scikit-learn. 1.4. Support Vector Machines. Disponível em: <https://scikit-learn.org/stable/modules/svm.html>
- [4] Medium. Máquina de Vetores de Suporte — SVM | by Matheus Remigio. Disponível em: <https://medium.com/@msremigio/m%C3%A1quinas-de-vetores-de-suporte-svm-77bb114d02fc>
- [5] Snowflake. Support Vector Machine (SVM) explicado: componentes e tipos. Disponível em: https://www.snowflake.com/pt_br/fundamentals/support-vector-machine/
- [6] Scikit-learn. RobustScaler. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.RobustScaler.html>
- [7] Scikit-learn. compute_class_weight. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.utils.class_weight.compute_class_weight.html