

Relatório Final — Comparação de Modelos (Pós-Auditoria Metodológica)

Classificação de cursos com alto risco de evasão acadêmica (ALTO_RISCO_EVASAO). Este documento substitui o relatório anterior em results/final_report.pdf, incorporando correções metodológicas validadas por auditoria estatística.

1. Resumo Executivo

A auditoria invalidou a conclusão anterior de que **Regressão Logística** seria o melhor modelo (Recall≈0.999). Com threshold corrigido, seu Recall cai para **0.503** e o score composto (0.581) fica **abaixo dos baselines triviais** (0.775).

O novo líder é **Árvore de Decisão** (Score=0.787, Recall=0.768, ROC-AUC=0.869). Wilcoxon entre Árvore de Decisão e SVM em Recall: $p=0.625$ — **sem diferença estatisticamente significativa** a $\alpha=0.05$.

2. Alterações Metodológicas (Antes vs Depois)

1. Seleção de threshold

Antes: maximização cega de F1 em `np.linspace(0.01, 0.99, 100)` sobre split de calibração (20% do treino).

Depois: Youden's J (sensibilidade + especificidade – 1) com busca restrita a [0.2, 0.8] e rejeição de thresholds cuja taxa de positivos previstos exceda 1,5× a prevalência real.

Motivo científico: maximizar F1 sem restrições permite thresholds no extremo inferior da grade, classificando quase tudo como positivo. Isso produz Recall≈1 e Accuracy≈Precision (padrão TN≈0), indistinguível do classificador trivial "sempre positivo". Youden's J penaliza explicitamente falsos positivos e falsos negativos de forma equilibrada.

2. Métricas independentes de threshold

Antes: comparação baseada principalmente em Accuracy, Precision, Recall e F1 no threshold otimizado.

Depois: inclusão obrigatória de ROC-AUC, PR-AUC e matriz de confusão (TP, FP, FN, TN) por fold.

Motivo científico: AUC mede discriminação independente do limiar. Quando ROC-AUC é mediano (~0.70) mas Recall no threshold escolhido é excelente (~0.99), há evidência de inflação por threshold, não de modelo superior.

3. Verificações de sanidade obrigatórias

Antes: ausentes no pipeline comparativo.

Depois: seis checagens por fold (invariante matemático, comparador trivial, plausibilidade do threshold, padrão degenerado, coerência AUC, sustentação para conclusões).

Motivo científico: em problemas de classificação com classes balanceadas (~50/50), um modelo que prevê sempre a classe positiva obtém Recall=1.0 e Accuracy=0.5 — métricas de threshold isoladas não detectam esse artefato.

4. Baselines triviais no ranking

Antes: apenas os cinco classificadores reais.

Depois: inclusão de "Sempre Positivo" e "Sempre Majoritário" com o mesmo score composto ($0.45 \cdot \text{Recall} + 0.30 \cdot \text{F1} + 0.15 \cdot \text{Precision} + 0.10 \cdot \text{Accuracy}$).

Motivo científico: qualquer modelo real deve superar claramente baselines triviais. Se não supera, o ganho reportado é metodológico, não preditivo.

5. Unificação do protocolo de avaliação

Antes: notebooks com pipelines distintos; Naive Bayes com data/preprocessamento.py (mediana, `QT_ING≥10`); comparação sem ROC-AUC em todos.

Depois: reavaliação com amostra 30k estratificada 50/50, alvo `TAXA_EVASAO≥20%`, pré-processamento `mode|label|corr|standard` por fold; SMOTE apenas no treino (NB).

Motivo científico: comparação válida exige mesmo alvo, mesma população e pré-processamento ajustado exclusivamente no treino de cada fold.

6. Teste de significância estatística

Antes: ausente; declaração categórica de "vencedor".

Depois: Wilcoxon pareado entre os dois melhores modelos em Recall (5 folds).

Motivo científico: diferenças em cinco folds podem ser instáveis; testes pareados avaliam se a diferença observada é estatisticamente distinguível do acaso.

3. Impacto na Regressão Logística (Caso Crítico)

A Regressão Logística ilustra o bug raiz: com threshold em 0.01–0.05, todos os folds apresentavam $\text{Accuracy} \approx \text{Precision} \approx 0.754$ e $\text{Recall} \approx 1.0$ — assinatura matemática de $\text{TN} \approx 0$ (classificar quase tudo como positivo). O GridSearchCV interno ($\text{F1} = 0.6675$ com threshold 0.5) já indicava desempenho moderado; o salto para $\text{F1} \approx 0.86$ vinha apenas do pós-ajuste de threshold degenerado.

Métrica	Regressão Logística (antes)	Regressão Logística (depois)
Recall	0.999	0.503
F1	0.860	0.596
Precision	0.754	0.734
Accuracy	0.754	0.660
ROC-AUC	N/A	0.699
Rank global	1	6

4. Ranking Anterior (Pré-Auditoria)

Rank	Modelo	Recall	F1	Score
1	Regressão Logística	0.999	0.860	0.896
2	Rede Neural	0.934	0.882	0.892
3	SVM	0.863	0.874	0.864
4	Árvore de Decisão	0.820	0.881	0.859
5	Naive Bayes	0.973	0.697	0.786

5. Ranking Revisado (Pós-Auditoria)

Rank	Modelo	Recall	F1	ROC-AUC	Score
1	Árvore de Decisão	0.768	0.793	0.869	0.787
2	SVM	0.773	0.791	0.822	0.787
3	Rede Neural	0.754	0.790	0.869	0.781
6	Regressão Logística	0.503	0.596	0.699	0.581
7	Naive Bayes	0.047	0.089	0.593	0.226

6. Tabela Completa Pós-Auditoria

Modelo	Acc	Prec	Rec	F1	ROC-AUC	PR-AUC	TN médio	Sanidade
Árvore de Decisão	0.800	0.824	0.768	0.793	0.869	0.861	2497	S
SVM	0.796	0.811	0.773	0.791	0.822	0.810	2457	S
Rede Neural	0.800	0.831	0.754	0.790	0.869	0.883	2538	S
Sempre Positivo	0.500	0.500	1.000	0.667	0.500	0.500	0	N
Sempre Majoritário	0.500	0.500	1.000	0.667	0.500	0.500	0	N
Regressão Logística	0.660	0.734	0.503	0.596	0.699	0.696	2450	S
Naive Bayes	0.519	0.841	0.047	0.089	0.593	0.597	2973	S

7. Discussão Científica por Modelo

Árvore de Decisão (1º no ranking revisado): ROC-AUC≈0.87 com TN médio≈2497 confirma discriminação real. Interpretabilidade via regras é vantagem prática. Risco de overfitting mitigado por poda (ccp_alpha) nos hiperparâmetros originais.


SVM (2º, estatisticamente equivalente à Árvore em Recall): margem máxima com kernel RBF captura fronteiras não lineares. Precision e Recall equilibrados (~0.77–0.81). Custo computacional maior, porém desempenho estável entre folds.



Rede Neural (3º): maior ROC-AUC (≈0.87) e bom Recall (≈0.75). Capacidade de representação não linear, porém menor interpretabilidade e dependência de tuning.

Regressão Logística (6º): após correção, Recall≈0.50 e ROC-AUC≈0.70 — desempenho mediano, compatível com separabilidade linear limitada. A versão anterior era metodologicamente inválida; o modelo mantém valor para interpretabilidade, não como líder em Recall.

Naive Bayes (7º): no pipeline unificado, Recall≈0.05 apesar de Precision≈0.84. A hipótese de independência e o pré-processamento ComplementNB+SMOTE não se adequaram a este dataset tabular com atributos correlacionados.

8. Visualizações (dados pós-auditoria)





9. Conclusão para Relatório Acadêmico

A comparação original entre modelos de evasão acadêmica continha um vício metodológico sistemático na seleção de threshold, que inflava artificialmente Recall e F1 da Regressão Logística e Naive Bayes. Após correção com Youden's J restrito, verificações de sanidade, baselines triviais e métricas AUC, conclui-se que:

- **Árvore de Decisão** e **SVM** são os modelos mais defensáveis para monitoramento de evasão com foco em Recall.
- **Regressão Logística** não deve ser declarada vencedora; seu desempenho anterior era artefato estatístico.
- Qualquer afirmação de superioridade deve citar ROC-AUC e TN, não apenas Recall no threshold otimizado.
- Para implantação institucional, recomenda-se SVM ou Árvore de Decisão, com Rede Neural como alternativa quando capacidade não linear é prioritária.