

GRUPO 10 | JUNHO DE 2026

Previsão de Evasão Universitária: Classificação de Risco

Comparação de Modelos de AM com Auditoria Metodológica

Gabriel Albertin

Gabriel Fonseca

João Pedro

Luiz Veloso

Victor Conde

O PROBLEMA: EVASÃO NO ENSINO SUPERIOR

75,4%

dos cursos de graduação no Brasil são afetados pelo fenômeno da evasão acadêmica.

- **Dataset:** Microdados do Censo da Educação Superior 2024 (INEP).
- **Amostra:** 30.000 cursos, amostragem estratificada 50/50.
- **Variável-alvo:** ALTO_RISCO_EVASAO ($\geq 20\%$ de desvinculação).
- **Atributos:** 21 variáveis preditivas, incluindo taxas de conclusão e eficiência acadêmica.

DATASET URL:
https://download.inep.gov.br/microdados/microdados_censo_da_educacao_superior_2024.zip

ESTRUTURA DO PIPELINE E PRÉ-PROCESSAMENTO

Pipeline modular de 5 etapas para garantir rigor científico e comparação justa.

- Protocolo:** 5-Fold Cross-Validation estratificada — ajuste de parâmetros apenas no treino.
- Threshold tuning:** Youden's J [0.2, 0.8] para evitar distorções estatísticas.
- Baseline:** Modelos triviais e dados crus como referência de desempenho.

ETAPA	TÉCNICAS TESTADAS
Valores Ausentes	Imputação pela Moda / Zero
Codificação	Label Encoding / One-Hot
Escalonamento	Standard / Robust / MinMax
Balanceamento	SMOTE / Class Weighting
Seleção	SelectKBest (MI) / Correlação

PRINCIPAIS COMBINAÇÕES TESTADAS

Não existe pipeline universal:
cada algoritmo exigiu uma
estratégia distinta.

MELHOR F1 (SVM)

0.837

Moda + Label + Standard

PIOR F1 (SVM)

0.396

Zero + Label + Robust

MODELO	MELHOR COMBINAÇÃO	DESTAQUE
Árvore de Decisão	Moda + Label + MI (23 features) + SMOTE + Poda (ccp_alpha)	Engenharia de features + poda
SVM	Moda + Label + Standard/Robust + Class Weight	Escalonamento crítico
Rede Neural	Moda + Label + Class Weight + Threshold calibrado	SGD + balanceamento
Regressão Logística	Moda + Label + Standard + GridSearch (C=10, L2)	Regularização leve
Naïve Bayes	ComplementNB + MinMax + SMOTE	Robustez ao desbalanceamento

COMPARAÇÃO DE RESULTADOS: AUDITORIA METODOLÓGICA

A correção do vício de threshold reverteu o ranking, expondo a fragilidade de modelos lineares.

- **O Bug:** Thresholds degenerados (0.01) inflavam o Recall artificialmente para 99.9%.
- **A Correção:** Otimização via Youden's J + restrição de taxa de positivos reais.

RANKING PRÉ-AUDITORIA (RESULTADOS INFLADOS)

Rank	Modelo	Recall	F1	Score
1º	Regressão Logística	0.999	0.860	0.896
2º	Rede Neural	0.934	0.882	0.892

RANKING PÓS-AUDITORIA (CORRIGIDO)

Rank	Modelo	Recall	F1	ROC-AUC
1º	Árvore de Decisão	0.768	0.793	0.869
2º	SVM	0.773	0.791	0.822
6º	Regressão Logística	0.503	0.596	0.699
7º	Naive Bayes	0.047	0.089	0.593

ANÁLISE COM MÉDIA E DESVIO PADRÃO (5-FOLD CV)

MODELO	ACURÁCIA (±DP)	F1 (±DP)	RECALL (±DP)	ROC-AUC
Árvore de Decisão	0.800 ± —	0.793 ± —	0.768 ± —	0.869
SVM	0.8125 ± 0.0056	0.8740 ± 0.0040	0.8626 ± 0.0056	0.822
Rede Neural (SGD)	0.8105 ± 0.0283	0.8820 ± 0.0112	0.9342 ± 0.0337	0.869
Regressão Logística	0.660 ± —	0.596 ± —	0.503 ± —	0.699

Baixo desvio padrão nos modelos líderes confirma a robustez real e estabilidade entre folds.

- **SVM:** Modelo mais estável (DP = 0.0040 no F1), garantindo previsões confiáveis independente da amostra.
- **Rede Neural:** Maior variância (DP = 0.0337 no Recall) devido à sensibilidade do SGD à inicialização dos pesos.
- **Wilcoxon:** p = 0.625 entre Árvore e SVM → sem diferença estatística significativa ($\alpha = 0.05$).

POR QUE ÁRVORE DE DECISÃO E SVM SE DESTACARAM?

Capacidade não linear + pré-processamento adequado + métricas independentes de threshold explicam a liderança.

ÁRVORE DE DECISÃO

- Captura relações não lineares e interações complexas entre variáveis educacionais.
- Poda via **ccp_alpha** evitou overfitting mesmo com profundidade média elevada.
- Engenharia de features + seleção por Informação Mútua maximizou o sinal preditivo.

SVM (KERNEL RBF)

- Kernel RBF captura fronteiras de decisão não lineares de alta complexidade.
- **RobustScaler** protegeu o modelo contra outliers críticos no dataset.
- Precisão consistente de 0.8857 entre folds, garantindo menor risco de falsos alertas.

POR QUE REGRESSÃO LOGÍSTICA E NAIVE BAYES FICARAM PARA TRÁS?

Limitações estruturais de cada algoritmo, amplificadas pelo dataset, explicam o baixo desempenho real.

REGRESSÃO LOGÍSTICA — 6ª POSIÇÃO

- **Modelo linear:** incapaz de capturar interações não lineares entre variáveis educacionais correlacionadas.
- **ROC-AUC = 0.699:** revela discriminação mediana — o Recall de 99.9% anterior era puro artefato de threshold.
- **Separabilidade limitada:** o problema de evasão envolve padrões complexos que um hiperplano não captura.

NAIVE BAYES — ÚLTIMA POSIÇÃO

- **Independência violada:** atributos do dataset são altamente correlacionados, quebrando a premissa do modelo.
- **Recall = 0.047:** no pipeline unificado, o modelo tornou-se praticamente inútil para detecção de risco.
- **Comparação justa:** expôs a fragilidade do modelo quando submetido ao mesmo rigor dos demais.

FEATURES MAIS IMPORTANTES: O QUE PREDIZ A EVASÃO?

FEATURE	IMPORTÂNCIA (ÁRVORE)	IMPORTÂNCIA (RF)	INFORMAÇÃO MÚTUA
RAZAO_ING_MAT	0.359	0.233	0.164
QT_ING	0.236	—	—
RAZAO_CONCLUSAO_EVASAO	0.198	—	—
TAXA_CONCLUSAO	0.102	0.067	0.052
QT_MAT	0.081	0.157	0.116

A dinâmica de renovação do corpo discente (RAZAO_ING_MAT) é o sinal mais forte de risco de evasão.

- **RAZAO_ING_MAT:** Cursos com alta rotatividade de ingressantes em relação ao corpo matriculado refletem diretamente o fenômeno de evasão.
- **RAZAO_CONCLUSAO_EVASAO:** Medida de eficiência acadêmica — cursos com baixa taxa de conclusão relativa à evasão já sinalizam o problema.
- **Variáveis demográficas:** Têm importância secundária, indicando que o problema é estrutural, não apenas demográfico.

COMPARAÇÃO DE ABORDAGENS DE APRENDIZADO

A natureza do aprendizado dita a adequação ao problema de evasão.

- **Modelos não lineares dominaram** devido às interações complexas entre variáveis educacionais.
- **Equilíbrio:** Árvore de Decisão oferece alta performance E regras interpretáveis para gestores.

ALGORITMO	TIPO DE APRENDIZADO	FRONTEIRA DE DECISÃO	INTERPRETABILIDADE
Árvore de Decisão	Não paramétrico, indutivo	Não linear (retangular)	Alta (regras explícitas)
SVM	Discriminativo, kernel	Não linear (RBF)	Baixa
Rede Neural	Conexionista, backprop	Não linear (piecewise)	Muito baixa
Regressão Logística	Paramétrico, linear	Linear (hiperplano)	Alta (odds ratios)

PRINCIPAIS CONCLUSÕES: O QUE REALMENTE IMPORTOU

Pré-processamento adequado e métricas independentes de threshold foram os fatores decisivos para resultados confiáveis.

IMPACTO POSITIVO

- **Youden's J:** Eliminou o vício metodológico que inflava o Recall artificialmente.
- **Engenharia de Features:** A criação da RAZAO_ING_MAT gerou o sinal preditivo mais forte do projeto.
- **SMOTE + Poda:** Permitiu o aprendizado da classe minoritária sem cair em overfitting.
- **RobustScaler:** Garantiu estabilidade ao SVM frente aos outliers do dataset educacional.

FALHAS E LIMITAÇÕES

- **Imputação por Zero:** Distorceu distribuições e destruiu a performance do SVM (F1 caiu para 0.396).
- **Maximização Cega de F1:** Produziu resultados ilusórios (Recall $\approx$ 1.0) sem capacidade real de separação.
- **Naive Bayes Unificado:** Hipótese de independência incompatível com a alta correlação dos atributos.

LIÇÕES APRENDIDAS E POSSÍVEIS MELHORIAS

A auditoria metodológica foi tão valiosa quanto os experimentos em si — rigor científico é inegociável.

LIÇÕES APRENDIDAS

- **ROC-AUC e TN são obrigatórios:** métricas de threshold isoladas podem ser enganosas.
- **Protocolo Unificado:** comparação válida exige mesmo dataset e pré-processamento por fold.
- **Baselines Triviais:** devem sempre estar no ranking para validar o ganho real do modelo.
- **Testes Estatísticos:** essenciais para validar a superioridade entre modelos líderes.

POSSÍVEIS MELHORIAS

- **Ensemble Methods:** Random Forest e Gradient Boosting para superar a Árvore simples.
- **Dados Temporais:** incorporar séries históricas do Censo para capturar tendências.
- **Calibração:** melhorar a qualidade dos scores de probabilidade dos modelos.
- **Recomendação:** implantação institucional via SVM ou Árvore de Decisão.

OBRIGADO!

GRUPO 10

Gabriel Albertin

Gabriel Fonseca

João Pedro

Luiz Veloso

Victor Conde

DÚVIDAS?

CIN0144 - APRENDIZADO DE MÁQUINA E
CIÊNCIA DE DADOS

CIN – UFPE | JUNHO DE 2026